Zero Edoardo, SMID

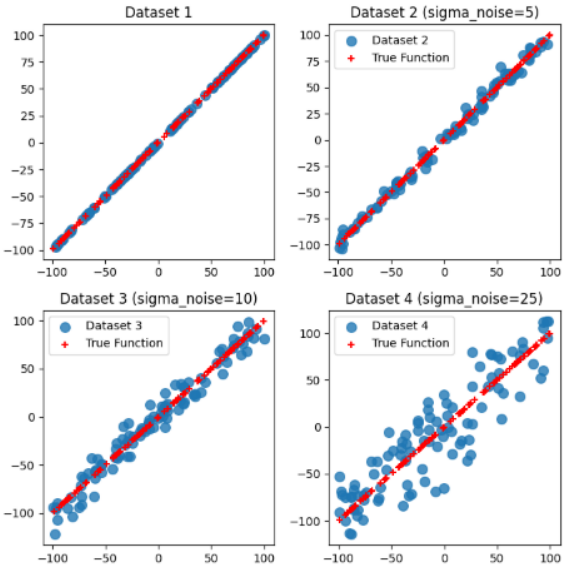
REPORT LABORATORIO GENERAZIONE DATI

Generating data for regression problems

Una volta definita la funzione *linearRegrFunction* che genera un dataset d-dimensionale, secondo una regressione lineare ,si è proseguito a creare dataset inizialmente unidimensionali ponendo *w*=1 e con *sigma-noise* =0 , facendo variare la numerosità campionaria *n*.
Osservando i grafici si poteva notare che con valori di *n* piccoli il grafico avrà pochi punti sulla retta generata dalla funzione lineare , mentre aumentando la grandezza di *n* i punti si distribuiscono in modo più uniforme e riempiono meglio lo spazio.

A questo punto , sempre considerando dataset unidimensionali si è aggiunto il *sigma-noise* e si sono generate quattro istanze diverse dei dati mantenendo tutti i parametri con lo stesso valore. Ogni istanza ha una distribuzione diversa per *X* e *Y* poiché si è aggiunto il rumore che causa delle variazioni nelle *Y*, se si aumentasse l'errore si potrebbero osservare maggiori differenze di distribuzione tra *X* e *Y*. Quindi i punti delle istanze si distribuiscono attorno alla *true function* con deviazioni causate dal rumore.

Successivamente si sono creati quattro dataset facendo variare il *sigma_noise* e confrontando le variazioni dei dati con la *true function* .

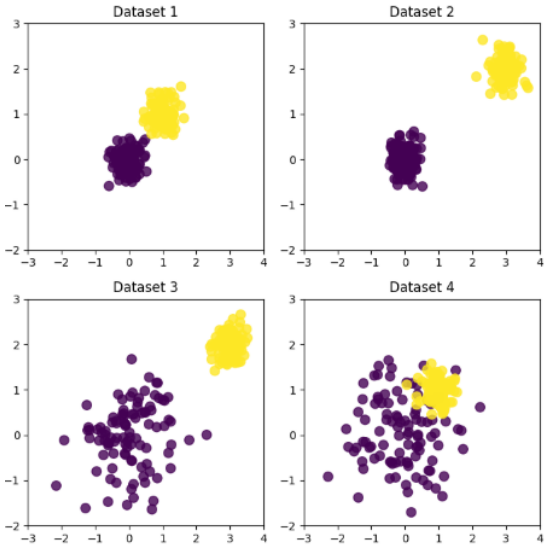


Nei primi due dataset si può osservare come la distribuzione dei dati sia molto simile a quella della *true function* in quanto i punti blu generati dalla regressione sono molto vicini alla funzione tracciata in rosso, questo è comprensibile in quanto l'errore assume valori non troppo alti (0.1 e 5) e quindi nell'intervallo di valori [-100;100] non causa una distorsione troppo evidente.
Negli ultimi due grafici ,invece, il rumore ha un impatto molto più significativo nella creazione del dataset , soprattutto nel *Datset 4.* Quindi con l'aumentare dei valori assunti dal *sigma_noise,* i punti osservati si discostano sempre più dalla *true function* , rendendo il pattern lineare meno evidente.

Generating data for classification problems

A questo punto si è studiata la generazione di dati per problemi di classificazione binaria.
Si è definita una funzione generatrice di dataset usando gaussiane 2D e , in seguito , si è proseguito generando quattro istanze di dataset mantenendo lo stesso numero di punti *n* , ma facendo variare i parametri della gaussiana.

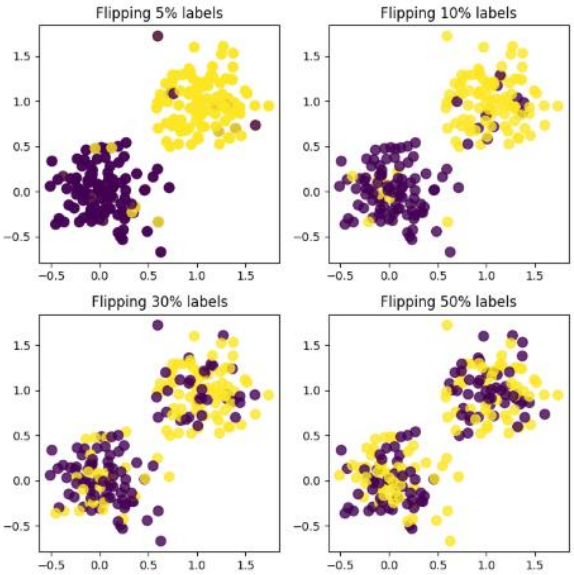
Nel primo dataset la nuvola di punti gialla è stata generata da una gaussiana avente la *media* nel punto (1,1) e avendo *standard deviation* uguale a 0.25, invece la nuvola di punti viola è stata generata da una gaussiana con la stessa *standard deviation* ma media centrata in (0,0). La concentrazione dei punti nelle due classi è praticamente uguale in quanto hanno la stessa *standard deviation* , ma le nuvole dei punti , avendo *medie* diverse , sono soggette a traslazioni.



In generale osservando gli altri dataset si può concludere che:

- Cambiando i centri, le distribuzioni delle Gaussiane si separano maggiormente o si avvicinano.
- Una *standard deviation* maggiore aumenta la dispersione dei punti rendendo le classi meno dense, ad esempio le classi viola nei dataset 3 e 4. Al contrario valori minori diminuiscono la dispersione dei dati e rendono le classi più dense, come nel *Dataset 1.*
- Con distribuzioni distanti e *standard deviation* minori è più facile riuscire a distinguere e separare i cluster. Ad esempio nel *Dataset 2*.

Si è proseguito aggiungendo anche una funzione che definisce il rumore *flibLabels*, in particolare inverte casualmente una percentuale di etichette di un problema di classificazione binaria. Quindi si sono generati quattro dataset mantenendo fissi tutti i parametri ma modificando la percentuale di etichette invertite.



Nei primi due dataset si sono invertite rispettivamente il 5% e il 10% delle etichette, considerando che la numerosità per ogni classe è 100 , le etichette capovolte non sono tante e quindi si riesce comunque a distinguere bene le due classi e renderle separabili. Al contrario con percentuali pari a 30% e 50% , *Dataset 3 e Dataset 4*, le inversioni aumentano significativamente rendendo più difficile distinguere i due cluster.
Infine sono state presentate due tecniche diverse per la generazione dei dati.
La prima permette di generare dataset più complessi utilizzando le distribuzioni gaussiane attraverso la funzione *mixGauss.* E' stato presentato un esempio che genera un dataset bidimensionale con quattro classi . Successivamente, manipolando i dati, il numero di classi è stato ridotto a due , aggregando coppie di classi. La seconda tecnica ha spiegato un modo differente per poter generare problemi di classificazione binaria utilizzando un *separatore lineare*. In sintesi dopo aver generato *n* punti casuali si è tracciata una retta che ha la funzione di separare i dati generati in due classi : quelli che si trovano sopra il *separatore* vengono assegnati alla classe +1 , gli altri alla classe -1. Infine è stato aggiungo un rumore e sono state invertite il 10% delle etichette .