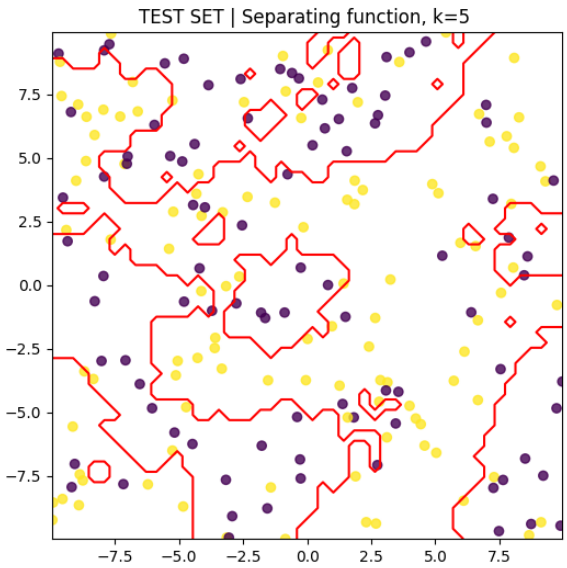
Zero Edoardo, SMID

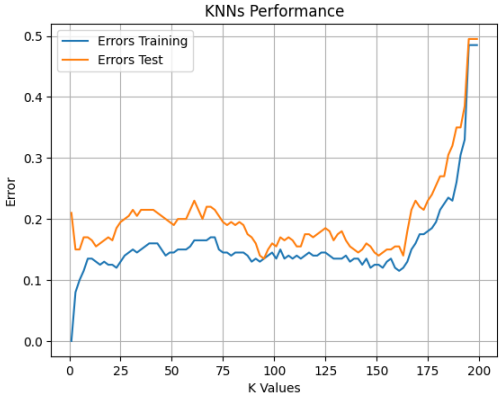
Laboratorio 1 : K-Nearest Neighbours

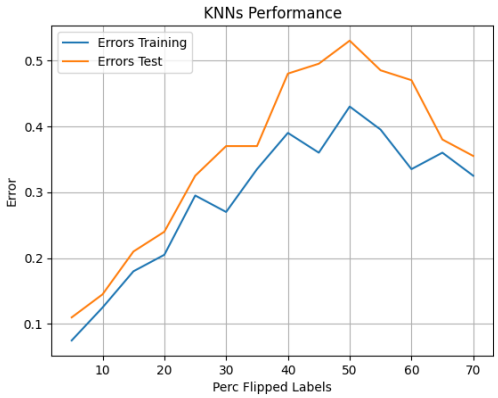
In questo laboratorio è stato studiato l'algoritmo dei KNN ed applicato in diversi casi. Innanzitutto dopo aver implementato la funzione *kNNclassify* che ritornava per ogni punto del Test Set il valore della sua classe predetta (1 o -1) , si è proseguito provando l'algoritmo sul Training Set poi su un Test Set , entrambi privi di errore, considerando il punto più vicino e si è calcolato l'errore tramite la funzione *calcError* . L'output : "*With K=1 the error on the training set is 0.0* " chiaramente se si calcola l'errore delle classi predette sul Training Set utilizzando il punto più vicino per ogni punto , cioè impostando K = 1, l'errore sarà pari a 0. Questo accade perché il punto del Training Set più vicino a ciascun punto è proprio se stesso , quindi la previsione dell'algoritmo corrisponderà sempre alla classe corretta. Di conseguenza non si produrrà alcun errore nella classificazione. Per quanto riguarda invece il Test Set ha prodotto un errore del 1,5% .



Successivamente si è svolto lo stesso procedimento aggiungendo però al Training Set un 10% di etichette invertite, l'errore sul Training Set era ancora nullo , mentre sul Test Set è aumentato arrivando a 25%, a questo punto si è proseguito mantenendo il rumore al 10% ma considerando K = 5. In questo ultimo scenario si è rilevato un incremento degli errori , soprattutto nel caso del Test Set raggiungendo un errore addirittura del 48% .

A questo punto sono stati analizzati tre diversi scenari per valutare la performance dell'algoritmo K-NN, misurata in base all'errore sul training set e sul test set .L'analisi è stata condotta considerando la variazione di diversi parametri: K , percentuale di etichette invertite e taglia campionaria del Training Set.





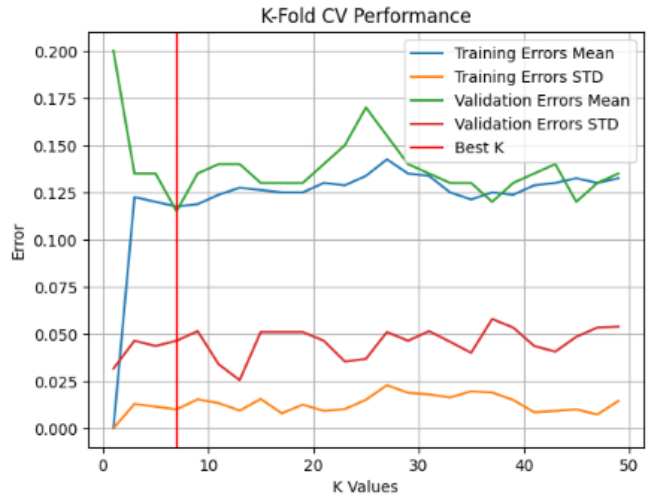


Come si può osservare dagli output dei tre scenari , l'errore sul Test Set è sempre maggiore rispetto a quello del Training Set , ciò non è sorprendente in quanto l'algoritmo è studiato per adattarsi al meglio al Training Set e quindi commetterà un errore maggiore quando vengono inseriti punti del Test Set.

Nell'ultima parte di laboratorio si sono studiati diversi metodi per trovare il migliore K , cioè quello che minimizza l'errore, data una lista *k_list* di valori possibili.
Inizialmente si è provato a scegliere il *best_k* utilizzando l'errore del Training Set , ma essendoci 1 nella lista dei k , sappiamo che per k=1 non si produce alcun errore sul Training Set ma se si verificava sul Test Set l'errore era 12%. Provando a togliere 1 e 2 dalla lista che producevano errore nullo nel training set e

calcolando l'errore del *best_k* nel Test Set , si è ottenuto un errore comunque abbastanza rilevante dal valore del 11%. Da questo si può concludere che questo metodo non è il migliore per la ricerca del K migliore, l'errore di training non fornisce buone stime sull'errore di test. Quindi usare l'errore di training per la selezione del modello significa che si selezionerà un K che non è adatto per il Test Set.
Allora si è studiato un altro metodo per stimare l'errore del test set : *K-Fold CV* , il dataset viene suddiviso in k *fold* , si addestra il metodo su k-1 *fold* e viene validato sull'ultimo , questo processo di ripete k volte ogni volta cambiando il *fold* di validazione , quindi alla fine si calcola la media dei k errori di modelli diversi.
Per testare il metodo , si è provato su una lista di k e si è selezionato il migliore :

```
The best K is :7
```



In questo caso la scelta K = 7 risulta la più ragionevole , poiché è il punto di minimo dell'errore medio di validazione. Per valori di K inferiori , l'errore medio di training è troppo basso mentre quello di validazione è alto, indicando un possibile problema di *overfitting*. Al contrario per valori di K maggiori le curve degli errori medi tendono a convergere suggerendo un potenziale problema di *underfitting*. Per quanto riguarda la *standard deviation* degli errori , quella relativa al training è più bassa rispetto a quella di validazione, ma rimangono complessivamente molto contenute.

Infine si sono studiati gli effetti del *rumore* sulla scelta del migliore K sul Test Set, confrontando due dataset con diverse percentuali di etichette invertite : il primo con il 20% e l'altro con il 5%. E' emerso che , con un livello di rumore più elevato , l'algoritmo tende a scegliere un valore di K maggiore (*best_k _test* = 11) con un conseguente elevato errore sul Test Set pari al 20%. Al contrario ,con un livello di rumore più basso, l'algoritmo tende a scegliere un valore di K minore (*best_k _test* = 5) e un errore più contenuto sul Test Set pari al 6.5%. Un rumore più elevato implica che ci siano più etichette invertite di conseguenza le due classi sono contaminate da più punti appartenenti alla classe opposta, è quindi più probabile che un punto del test set capiti in una situazione in cui i punti vicini siano sia di una classe sia dell'altra , l'algoritmo , quindi, avrà bisogno di un numero maggiore di punti per attribuire il punto di test alla classe giusta , aumentando l'errore.