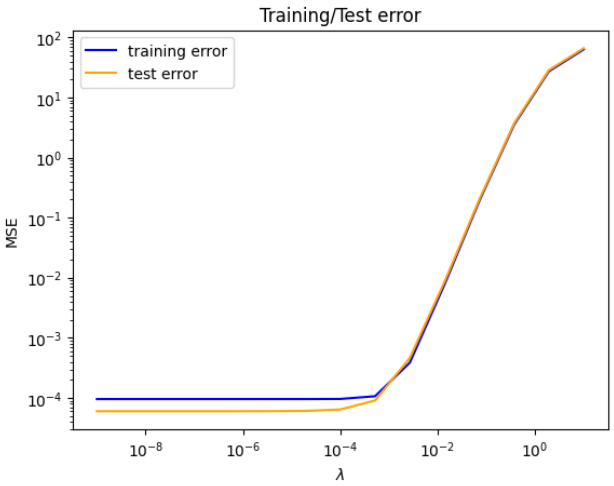
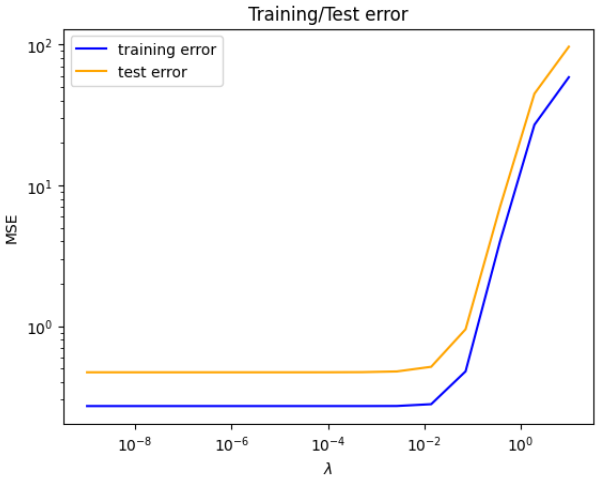
Zero Edoardo, SMID

Laboratorio 2 : Regularized Least Square

Per iniziare è stata definita la funzione *regularizedLSTraining* che presi in input il Training Set generato e un *lambda* (parametro di regolarizzazione) fissato ,restituisce il vettore *w* , la soluzione del sistema di regressione regolarizzata: $(X_{tr}^{\intercal}X_{tr} + \lambda nI)w = X_{tr}^{\intercal}Y_{tr}$. Quindi si è definita una seconda funzione *regularizedLSTest* che , preso il *w* e le osservazioni di test , permette di calcolare le predizioni. Allenando il modello RLS tramite l'uso combinato di *regularizedLSTraining* e *regularizedLSTest* , impostando un valore *lambda* molto basso, calcolando l'errore si osserva che gli errori del train set e del test set risultano molto contenuti.
In seguito si è studiato il comportamento degli errori del train e del test al variare dei valori di *lambda* da 10^{-9} a 0 .

noise_std =0.01

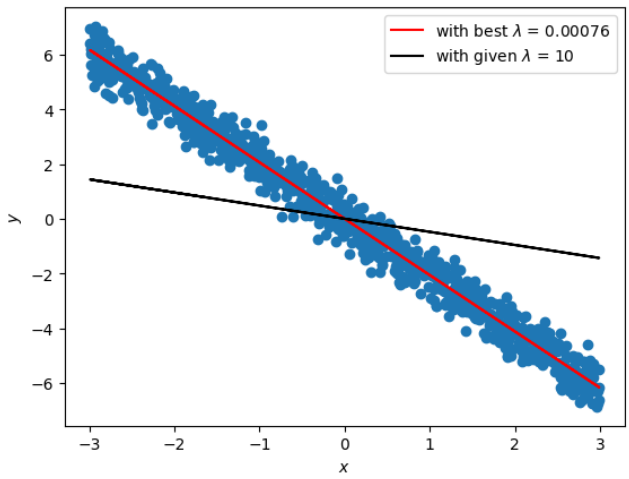




noise_std =0.5

Innanzitutto si osserva che l'andamento del training error e del test error è molto simile:
gli errori del train e del test sono minimizzati da valori di *lambda* bassi e gli errori crescono con l'aumentare del valore di *lambda.* Invece, aumentando il livello di rumore dei dati la curva diventa più ripida e si osserva un incremento degli errori per valori bassi del parametro *lambda*.

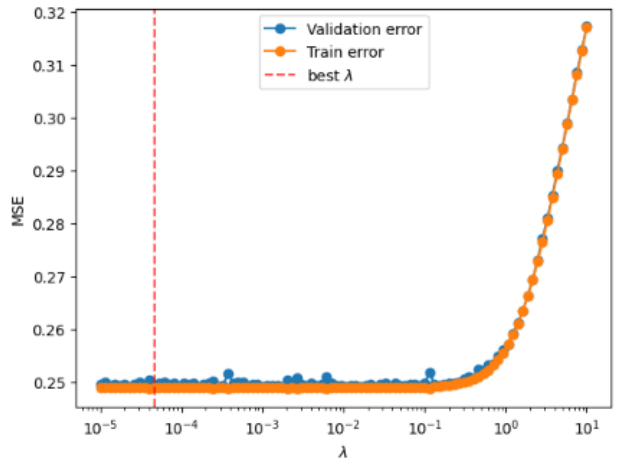
Per trovare il valore ottimale di *lambda* è stata implementata la tecnica *K-Fold Cross Validation* che ritorna il *lambda* migliore (quello che minimizza l'errore di validazione) insieme alla varianza e alla media degli errori di validazione e del training.



Per verificare il corretto funzionamento della *K-Fold* è stato plottato il grafico della regressione utilizzando il miglior *lamda* e confrontandolo con un valore di *lambda* casuale. Quindi il *lambda* ottenuto dalla *Cross-Validation* produce risultati migliori in termini di generalizzazione.

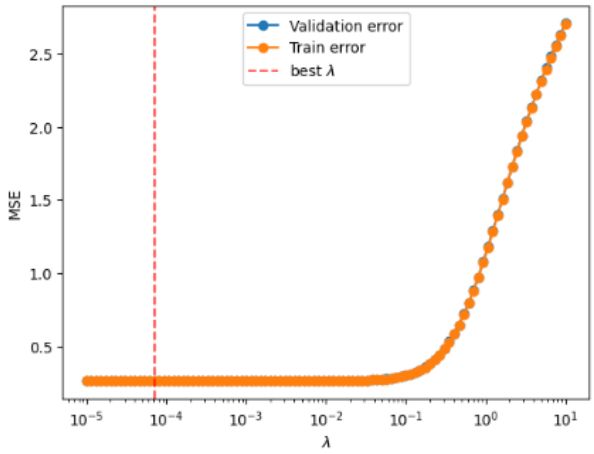
Infine è stato studiato il comportamento della scelta del migliore lambda aumentando la dimensionalità del campione , ponendo D=2 . In questo caso ,come nel modello precedente ,il modello è sotto-parametrizzato (n>D) .
Con un numero maggiore di dimensioni il problema diventa più complesso , tuttavia D=2 è una dimensione abbastanza contenuta e non cambia molto da quello unidimensionale a livello di complessità. In generale ci si può aspettare che la scelta del migliore *lambda* possa essere leggermente diversa , in particolare più grande in quanto essendo un parametro regolarizzatore deve fare conto di una complessità maggiore.

```
Best lambda found: 4.641588833612782e-05
<matplotlib.legend.Legend at 0x7d4a036e3a10>
```



D = 1

```
Best lambda found: 7.054802310718646e-05
<matplotlib.legend.Legend at 0x7d4a036bba10>
```



D = 2

Come si può osservare dai grafici e dall'output , il *lambda* nel caso di D=2 è leggermente superiore rispetto al caso D = 1.