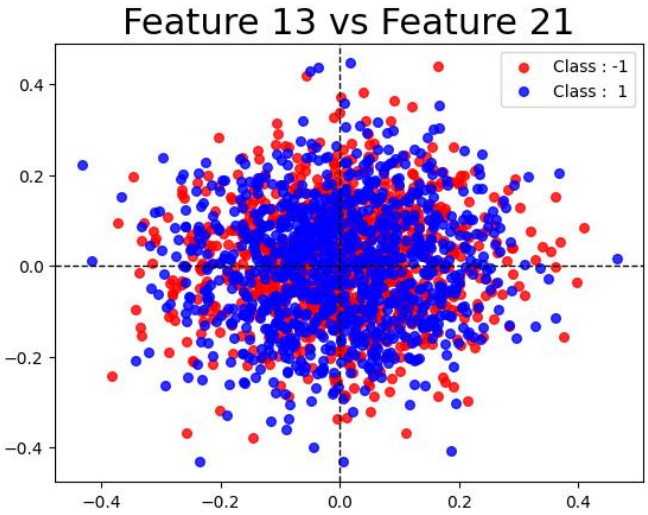
Zero Edoardo, SMID

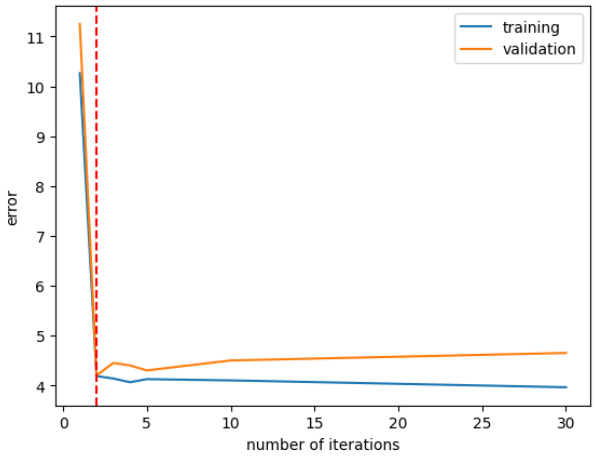
Laboratorio 6 : Orthogonal Matching Pursuit

In questo laboratorio è stato approfondita l'applicazione dell'algoritmo OMP per la selezione di variabili rilevanti in un contesto di classificazione.
Inizialmente è stata definita la funzione generatrice dei dati *mixGauss* con la quale sono stati creati il dataset di training e quello di test , in particolare questa funzione è stata utilizzata per generare le osservazioni delle prime due variabili rilevanti attribuendoli delle etichette con valori -1 e 1 in base al centro della nuvola dei dati della normale . Successivamente i dataset delle *Xtr* e *Xte* sono stati completati concatenando altre 28 variabili fittizie che assumevano valori casuali presi da una distribuzione di una variabile normale di media 0 e varianza 0.13^2, quindi sono state concatenate al dataset iniziale di dimensioni (2000,2) , senza portare nessuna modifica alle etichette già attribuite in precedenza.



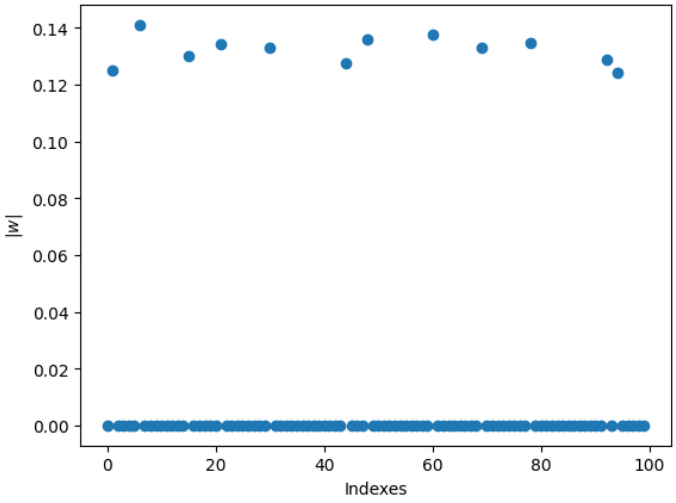
Per osservare meglio la nullità di informazione di queste variabili , è stato generato un grafico rappresentante le nuvole dei punti delle feature 13 e 21, in rosso le osservazioni etichettate con -1 in blu quelle etichettate con 1 . Sostanzialmente i valori dei dati per le variabili dalla terza in poi sono uguali o almeno leggermente diversi ma generati randomicamente dalla stessa funzione , ciò comporta che , come si vede dal grafico, i valori delle Xtr , per le variabili 13 e 21 con etichette diverse , sono uguali e quindi non influenzano in nessun modo la classificazione, che era già stata decisa prima ancora di completare concatenando i dataset.

In seguito è stata implementata la funzione dell'algoritmo OMP che calcola una rappresentazione sparsa di un segnale , cioè una combinazione lineare di un numero ridotto di variabili selezionate da un dizionario, tale da approssimare il segnale originale , minimizzando i coefficienti non nulli nella rappresentazione. L'algoritmo OMP prende in input il training set e un numero di iterazioni che corrisponde esattamente al numero di variabili significative che si ha intenzione di selezionare. In questo caso non avrebbe senso selezionare più di due iterazioni , e quindi variabili, in quanto per costruzione le uniche variabili rilevanti sono le prime due , impostando un numero maggiore di iterazioni l'algoritmo restituisce più variabili ma con pesi vicino allo zero in quanto comunque poco rilevanti.



In generale non sapendo a priori il numero di variabili da selezionare è utile implementare il processo della Cross Validation sul numero di iterazioni da usare per l'algoritmo OMP, quindi è stata implementata la funzione per la *K-Fold* sull'algoritmo OMP , e provandola risultava che effettivamente il numero di iterazioni da scegliere ,in questo caso, era proprio 2.

Infine si è creato un dataset di addestramento e uno di test facendo aumentare il numero di variabili , arrivando a 100 e considerando 20 variabili rilevanti, il metodo con la quale sono stati creati è lo stesso del caso precedente, concatenando però 80 variabili fittizie e mescolando le variabili in ordine sparso in modo che le prime 20 non siano quelle significative.



Utilizzando la funzione OMP e assegnando 12 iterazioni, come si osserva dal grafico, l'algoritmo attribuisce pesi ,in modulo, maggiori di zero alle 12 variabili rilevanti e pesi nulli a quelle fittizie.
L'errore commesso sulla predizione delle etichette è del 1.775% .